
Python 金融数据分析

第 5 章 *Matplotlib* 可视化

主讲人： 王伟冠, 吕文俊
院 系： 经济学院金融系

上海大学

2026 年 9 月 24 日



1. 数据简介
2. 直方图与绘图流程
3. 柱状图：比较类别
4. 折线图与面积图
5. 散点图：观察关系
6. 图形布局与保存
7. 练习与小结



1. 数据简介
2. 直方图与绘图流程
3. 柱状图：比较类别
4. 折线图与面积图
5. 散点图：观察关系
6. 图形布局与保存
7. 练习与小结



- Capital Bikeshare 的历史租车记录：2011-01-01 至 2012-12-31。
- 数据按天汇总，保存在 `day.csv` 中，共 731 天、16 列。
- 租车量表示**次数**，同一个人可以租多次。
- 数据已放入本章 `data/`，课堂只读本地文件。

来源与使用许可

Hadi Fanaee-T (2013), *Bike Sharing*, UCI Machine Learning Repository.
DOI: 10.24432/C5W894; CC BY 4.0.^[1]

摘自 `day.csv` 的前 5 行，展示日期与当天总租车次数。

日期	总租车次数
<code>dteday</code>	<code>cnt</code>
2011-01-01	985
2011-01-02	801
2011-01-03	1349
2011-01-04	1562
2011-01-05	1600

怎样读一行？

第一行表示：2011 年 1 月 1 日共发生 985 次租车。
每行对应一天；985 是租车次数，不是 985 位不同的用户。

先看几天的租车记录。cnt 表示当天的总租车次数，路径变量 DATA 已在 Notebook 开头设置。

```
1 bike = pd.read_csv(DATA / "day.csv", parse_dates=["dteday"])
2 bike = bike.sort_values("dteday").reset_index(drop=True)
3 print(bike.shape)
4 print(bike[["cnt"]].head(7))
```

输出形状为 (731, 16)。前七天租车量：985、801、1349、1562、1600、1606、1510。

1. 数据简介
- 2. 直方图与绘图流程**
3. 柱状图：比较类别
4. 折线图与面积图
5. 散点图：观察关系
6. 图形布局与保存
7. 练习与小结



- 原始数据：每行一个日期，cnt 是当天租车次数。
- 直方图：横轴把租车次数分成区间，纵轴数落在区间里的**天数**。
- 成绩分箱数的是学生人数；这里使用同样原理，只把观察单位换成天。

先用原表前七行手算

985、801、1349、1562、1600、1606、1510。

按 $[0, 1000)$ 、 $[1000, 1500)$ 、 $[1500, 2000]$ 分箱：分别为 2、1、4 天。
后面画全体 731 天，改用覆盖完整取值范围的分箱。

```
1 import matplotlib.pyplot as plt
2 plt.rcParams["font.sans-serif"] = ["Microsoft YaHei"]
3 plt.rcParams["axes.unicode_minus"] = False
```

- Windows 常用微软雅黑；macOS 可用 PingFang SC。
- 配套 Notebook 自动选用本机已安装的常见中文字体。
- `fig` 是整张画布；`ax` 是画布上的一个坐标系。


第一步 subplots 建画布和坐标系；第二步 hist 接收原始日租车量，自动完成分箱计数。

```
1 bin_edges = [0, 2000, 4000, 6000, 8000, 10000]
2 fig, ax = plt.subplots(figsize=(8, 4))
3 ax.hist(bike["cnt"], bins=bin_edges,
4         color="#2B6A6C", edgecolor="white")
5 plt.show()
```


```
1 fig, ax = plt.subplots(figsize=(8, 4))
2 ax.hist(bike["cnt"], bins=bin_edges,
3         color="#2B6A6C", edgecolor="white")
4 ax.set_title("每天租车量的分布 (2011—2012, 731天)")
5 ax.set_xlabel("租车量 (次/日)")
6 ax.set_ylabel("天数")
7 ax.set_xticks(bin_edges)
8 ax.grid(axis="y", alpha=0.2)
9 fig.tight_layout()
10 plt.show()
```

set_title 对应顶部；set_xlabel / set_ylabel 对应坐标轴外文字；grid 对应淡网格。

只有 hist



加上标题、单位、刻度和网格



从左到右，数据与分箱完全相同；标题和轴标签让读者知道“柱高数的是天，不是租车次数”。

租车次数区间	天数
[0, 2000)	98
[2000, 4000)	181
[4000, 6000)	272
[6000, 8000)	168
[8000, 10000]	12

五根柱子的高度相加为 731 天。


最高一箱为 [4000, 6000)，共有 272 天。

`bins` 决定边界；`hist` 自动数每一箱的观测。

除最后一箱外左闭右开，最后一箱包括右端点。

同样的 731 个值，共用横纵轴范围。这里用整数指定分箱数量，而不是手写分箱边界。


```
1 fig, axes = plt.subplots(1, 3, figsize=(10, 3.5),
2                           sharex=True, sharey=True)
3 for ax, bins in zip(axes, [10, 30, 60]):
4     ax.hist(bike["cnt"], bins=bins,
5             color="#2B6A6C", edgecolor="white")
6     ax.set(title=f"bins={bins}", xlabel="租车量 (次/日)")
7 axes[0].set_ylabel("天数")
8 fig.tight_layout()
9 plt.show()
```



箱数少会合并细节；箱数多会出现更细碎的起伏。数据没有改变，不能把分箱造成的变化当作新的事实。

为便于读数，两图都把同一列除以 1000，单位改成千次/日；仍然是同一组记录。

```
1 fig, axes = plt.subplots(1, 2, figsize=(9, 3.8))
2 for ax, density in zip(axes, [False, True]):
3     ax.hist(bike["cnt"] / 1000, bins=np.array(bin_edges) / 1000,
4             density=density, color="#2B6A6C", edgecolor="white")
5     ax.set(title=f"density={density}", xlabel="租车量（千次/日）")
6 axes[0].set_ylabel("天数")
7 axes[1].set_ylabel("密度（每千次/日）")
8 fig.tight_layout()
9 plt.show()
```




最高一箱宽度为 2：频数是 272，密度是 $272 / (731 \times 2) \approx 0.186$ ，面积约为 0.372，即 37.2%。密度柱高不是概率。

1. 数据简介
2. 直方图与绘图流程
- 3. 柱状图：比较类别**
4. 折线图与面积图
5. 散点图：观察关系
6. 图形布局与保存
7. 练习与小结





分布图没有区分日类型。要比较工作日与非工作日，可用 `workingday`: 1 表示既非周末又非节假日，0 表示其他日子。先求各组均值。

```
1 work_summary = bike.groupby("workingday")["cnt"].agg(["mean", "size"])
2 work_labels = ["非工作日", "工作日"]
3 print(work_summary.round(1))
4 fig, ax = plt.subplots(figsize=(7, 4))
5 ax.bar(work_labels, work_summary["mean"], color="#2B6A6C")
6 ax.set(title="不同日类型的日均租车量（2011—2012）",
7       xlabel="日类型", ylabel="平均租车量（次/日）", ylim=(0, 5500))
8 fig.tight_layout()
9 plt.show()
```



非工作日有 231 天，日均约 4330 次；工作日有 500 天，日均约 4585 次。两组天数不同，比较总次数会混入样本天数的影响。

```
1 fig, axes = plt.subplots(1, 2, figsize=(10, 4))
2 axes[0].bar(work_labels, work_summary["mean"], color="#2B6A6C")
3 axes[0].set(title="bar: 比较两个类别", ylabel="平均租车量 (次/日)")
4 axes[1].hist(bike["cnt"], bins=bin_edges,
5             color="#2B6A6C", edgecolor="white")
6 axes[1].set(title="hist: 统计数值区间", xlabel="租车量 (次/日)", ylabel="天数")
7 fig.tight_layout()
8 plt.show()
```



左边输入“类别与算好的均值”，每根柱子对应一类日子；右边输入原始 cnt，自动分箱，每根柱子对应一个租车量区间。

- ① 两组均值接近，是否说明每一天的租车量都接近？
- ② 两类日子的总量接近，是否说明用户构成也一样？
- ③ 如果先用 `sum()` 再画柱状图，纵轴该写什么单位？

先保留问题


均值只能概括平均水平。判断每天是否相似，要看分布；判断用户构成是否相似，需要区分用户类型。

1. 数据简介
2. 直方图与绘图流程
3. 柱状图：比较类别
- 4. 折线图与面积图**
5. 散点图：观察关系
6. 图形布局与保存
7. 练习与小结



前面的分布和均值没有显示时间顺序。要看租车量何时高、何时低，需要用日期 `dteday` 作横轴，并按日期排序。


```
1 fig, ax = plt.subplots(figsize=(9, 4))
2 ax.plot(bike["dteday"], bike["cnt"],
3         color="#2B6A6C", linewidth=0.9)
4 ax.set(title="每日租车量（2011—2012，731天）",
5        xlabel="日期", ylabel="租车量（次/日）")
6 ax.grid(alpha=0.2)
7 fig.tight_layout()
8 plt.show()
```



横轴是日期，纵轴仍是 cnt；连线表示相邻日期。两年中都有起伏，单个高低点的原因不能只凭这张图认定。

每日曲线起伏较多，可以先看每个月平均水平。`resample("MS")` 按月分组，`mean()` 求月内日均值，得到 24 个点。


```
1 monthly = bike.set_index("dteday").resample("MS")["cnt"].mean()
2 fig, ax = plt.subplots(figsize=(9, 4))
3 ax.plot(monthly.index, monthly, color="#2B6A6C",
4         marker="o", linewidth=2, label="月内日均租车量")
5 ax.set(title="月内日均租车量（2011—2012，24个月）",
6        xlabel="月份", ylabel="月内平均租车量（次/日）")
7 ax.legend()
8 ax.grid(alpha=0.2)
9 fig.tight_layout()
10 plt.show()
```



marker="o" 标出 24 个月；label 提供图例文字，legend() 显示图例。月均值减少每日波动，不能读作月度总次数。

用前七天的租车记录观察线条样式。每幅只改变一个参数，便于对应代码与效果。


```
1 week = bike.head(7)
2 styles = [{}, {"color": "#B40D49"}, {"linestyle": "--"},
3           {"marker": "o"}, {"linewidth": 4}, {"alpha": 0.25}]
4 titles = ["默认", "color", "linestyle='--'", "marker='o'",
5           "linewidth=4", "alpha=0.25"]
6 fig, axes = plt.subplots(2, 3, figsize=(10, 5), sharex=True, sharey=True)
7 for ax, style, title in zip(axes.flat, styles, titles):
8     ax.plot(week["dteday"].dt.day, week["cnt"], **style)
9     ax.set(title=title, xticks=[1, 3, 5, 7])
10 fig.supxlabel("2011年1月的日期")
11 fig.supylabel("租车量 (次/日)")
12 fig.tight_layout()
13 plt.show()
```



颜色、虚线、圆点、粗细、透明度分别由一个参数控制。实际画图时可以把这些参数组合起来；参数改变外观，不改变原始值。

总量的变化来自哪些用户？casual 记录临时用户租车次数，registered 记录注册用户租车次数；两类之和等于 cnt。分别画线可以比较各自的变化。


```
1 user_monthly = bike.set_index("dteday").resample("MS")[["casual", "registered",  
    "cnt"]].mean()  
2 fig, ax = plt.subplots(figsize=(9, 4))  
3 ax.plot(user_monthly.index, user_monthly["casual"],  
4         color="#B40D49", linestyle="--", label="临时用户")  
5 ax.plot(user_monthly.index, user_monthly["registered"],  
6         color="#2B6A6C", label="注册用户")  
7 ax.set(title="两类用户的月内日均租车量（2011—2012）",  
8        xlabel="月份", ylabel="平均租车量（次/日）")  
9 ax.legend()  
10 fig.tight_layout()  
11 plt.show()
```



每次 plot 增加一条线；实线与虚线也能区分类别。两条曲线仍来自同样的 24 个月，纵轴单位一致。

工作日与非工作日的日均总量接近，两类用户是否也如此？分别计算各组的临时、注册用户日均租车量，用并排的柱子比较。


```
1 user_work = bike.groupby("workingday")[["casual", "registered"]].mean()
2 x = np.arange(2)
3 fig, ax = plt.subplots(figsize=(7, 4))
4 ax.bar(x - 0.18, user_work["casual"], width=0.36,
5        color="#B40D49", label="临时用户")
6 ax.bar(x + 0.18, user_work["registered"], width=0.36,
7        color="#2B6A6C", label="注册用户")
8 ax.set_xticks(x, work_labels)
9 ax.set(title="按日类型拆开用户构成（2011—2012）", ylabel="平均租车量（次/日）")
10 ax.legend()
11 fig.tight_layout()
12 plt.show()
```



临时用户：非工作日约 1371 次/日，工作日约 607；注册用户：约 2959 与 3978。总量接近可以掩盖构成差异；图本身不能证明出行目的。

下层从 0 填到 registered, 上层从 registered 填到 cnt。上下两层的厚度分别对应两类租车辆。

```
1 fig, ax = plt.subplots(figsize=(9, 4))
2 ax.fill_between(user_monthly.index, 0, user_monthly["registered"],
3                 color="#2B6A6C", alpha=0.6, label="注册用户")
4 ax.fill_between(user_monthly.index, user_monthly["registered"],
5                 user_monthly["cnt"], color="#B40D49", alpha=0.45, label="临时用
   户")
6 ax.set(title="月内日均租车量的构成 (2011—2012)",
7         xlabel="月份", ylabel="平均租车量 (次/日)", ylim=(0, 8000))
8 ax.legend()
9 fig.tight_layout()
10 plt.show()
```




fill_between(x, y1, y2) 填充两条边界之间的区域；alpha 控制透明度。最上方边界是总量，上层厚度才是临时用户量。

1. 数据简介
2. 直方图与绘图流程
3. 柱状图：比较类别
4. 折线图与面积图
- 5. 散点图：观察关系**
6. 图形布局与保存
7. 练习与小结



租车量的起伏是否与温度有关？用标准化温度 `temp` 与同一天的 `cnt` 配成一个点，观察二者的关系。`temp` 不是摄氏度。


```
1 fig, ax = plt.subplots(figsize=(7, 4.5))
2 ax.scatter(bike["temp"], bike["cnt"],
3            color="#2B6A6C", alpha=0.45, s=22)
4 ax.set(title="温度与每日租车量（2011—2012，731天）",
5        xlabel="标准化温度 temp（无量纲）", ylabel="租车量（次/日）")
6 ax.grid(alpha=0.2)
7 fig.tight_layout()
8 plt.show()
```



每个点代表一天。较暖的日子总体对应较高租车量，但同一温度附近仍有很大差异。
alpha 减少重叠遮挡，s 控制点的面积。

相近温度下，租车量仍有很大差异，会不会与年份有关？用 yr 区分 2011 (0) 与 2012 (1)，以颜色和点形标记，横纵轴保持不变。

```
1 fig, ax = plt.subplots(figsize=(7, 4.5))
2 for year, color, marker in [(0, "#2B6A6C", "o"), (1, "#B40D49", "^")]:
3     part = bike[bike["yr"] == year]
4     ax.scatter(part["temp"], part["cnt"], color=color,
5               marker=marker, alpha=0.5, s=24, label=str(2011 + year))
6 ax.set(title="按年份区分温度与租车量 (2011—2012)",
7       xlabel="标准化温度 temp (无量纲)", ylabel="租车量 (次/日)")
8 ax.legend()
9 fig.tight_layout()
10 plt.show()
```



2012 年的点群整体偏高；同一张无分组散点图混合了年份差异。分组展示有助于发现结构，但没有控制所有影响因素，也不能据此确定因果。

- `hum`: 标准化湿度，可乘 100 表示百分比。
- `weathersit`: 天气类别，日表实际出现 1、2、3。
- `workingday`: 工作日结构可能与租车行为相关。

下一步可以研究什么？

湿度较高时，租车量是否不同？不同天气类别之间是否有差异？根据具体问题选择散点图、分组比较或子图。


本章做描述性探索；季节、年份、天气等因素可能同时变化，图形关系不自动等于因果关系。

1. 数据简介
2. 直方图与绘图流程
3. 柱状图：比较类别
4. 折线图与面积图
5. 散点图：观察关系
- 6. 图形布局与保存**
7. 练习与小结




2, 1 表示两行一列。axes[0] 在上, axes[1] 在下; sharex=True 共享月份范围。

```
1 fig, axes = plt.subplots(2, 1, figsize=(9, 5), sharex=True)
2 axes[0].plot(user_monthly.index, user_monthly["cnt"], color="#2B6A6C")
3 axes[0].set(title="总租车量", ylabel="平均租车量 (次/日)")
4 axes[1].plot(user_monthly.index, user_monthly["casual"], color="#B40D49")
5 axes[1].set(title="其中: 临时用户租车量", xlabel="月份", ylabel="平均租车量 (次/日)")
6 fig.suptitle("月内日均租车量 (2011—2012)")
7 fig.tight_layout()
8 plt.show()
```



DataFrame.plot 默认把索引作为横轴、每列作为一条线。返回的仍是 Matplotlib 坐标系。

```
1 ax = user_monthly[["casual", "registered"]].plot(  
2     figsize=(9, 4), color=["#B40D49", "#2B6A6C"],  
3     style=["--", "-"], grid=True)  
4 ax.set(title="pandas 快捷绘图：两类用户（2011—2012）",  
5         xlabel="月份", ylabel="月内平均租车量（次/日）")  
6 ax.legend(["临时用户", "注册用户"])  
7 fig = ax.figure  
8 fig.tight_layout()  
9 plt.show()
```




这与前面的两条用户曲线使用完全相同的数据。探索时可以使用 pandas 快捷接口，需要细调时继续调用 `ax` 的方法。

axes[行, 列] 从 0 开始。先完成上面一行；接着运行下一页代码，填满同一张画布。

```
1 fig, axes = plt.subplots(2, 2, figsize=(11, 7))
2 axes[0, 0].plot(monthly.index, monthly, color="#2B6A6C")
3 axes[0, 0].set(title="月内日均租车量", xlabel="月份", ylabel="次/日")
4 tick_dates = monthly.index[[0, 6, 12, 18, 23]]
5 axes[0, 0].set_xticks(tick_dates, tick_dates.strftime("%Y-%m"))
6 axes[0, 1].bar(work_labels, work_summary["mean"], color="#2B6A6C")
7 axes[0, 1].set(title="日类型比较", ylabel="平均租车量（次/日）")
8 plt.close(fig) # 暂不显示，下一单元格继续完成
```

```
1 axes[1, 0].hist(bike["cnt"], bins=bin_edges,  
2               color="#2B6A6C", edgecolor="white")  
3 axes[1, 0].set(title="每日租车量分布", xlabel="次/日", ylabel="天数")  
4 axes[1, 1].scatter(bike["temp"], bike["cnt"],  
5                  color="#2B6A6C", alpha=0.4, s=10)  
6 axes[1, 1].set(title="温度与每日租车量", xlabel="标准化温度", ylabel="次/日")  
7 fig.suptitle("同一张日表的四个视角 (2011—2012, 731天)")  
8 fig.tight_layout()  
9 display(fig) # 显示前一单元格创建、现已完成的画布
```

同一张日表的四个视角（2011—2012，731天）



左上和时间，右上是类别，左下是分布，右下是关系。四幅图来自同一张表，但统计单位与纵轴含义并不完全相同。

fig 保留对刚才画布的引用。文件名后缀决定 PNG 或 PDF；输出都放在本章 outputs/。

```
1 fig.savefig(OUTPUTS / "bike_report.png", dpi=300, bbox_inches="tight")
2 fig.savefig(OUTPUTS / "bike_report.pdf", bbox_inches="tight")
```

dpi 控制位图分辨率；bbox_inches="tight" 收紧外围空白。保存后，打开文件核对图形与单位。

1. 数据简介
2. 直方图与绘图流程
3. 柱状图：比较类别
4. 折线图与面积图
5. 散点图：观察关系
6. 图形布局与保存
- 7. 练习与小结**



- ① 用 `hum * 100` 与 `cnt` 画散点图，正确标注湿度单位。
- ② 按 `weathersit` 比较日均租车量，同时列出各组天数。
- ③ 给月均租车量曲线加一条全样本日均值的水平虚线。

每幅图写两句话

一句写图直接支持的观察；另一句写图还不能支持的解释。参考答案在 Notebook 折叠区域。

- **观察单位**：每行一天，租车量表示次数；汇总后注意单位变化。
- **先提问**：分布用 hist；类别比较用 bar；时间变化用 plot；两变量关系用 scatter。
- **再汇总**：逐日值、分组均值、月均值回答不同问题。
- **最后表达**：标题、单位、图例、样本范围、子图与 savefig。

已看到的具体例子

工作日与非工作日的总量均值较接近，但用户类型构成不同。增加两列，就能提出更具体的问题。

本章操作	图形	金融数据中的对应问题
每日租车量分布	hist	日收益率分布
不同日类型均值	bar	不同行业或资产的指标比较
按日期画租车量	plot	价格、成交量随时间变化
两条边界间填充	fill_between	收益区间或回撤区域
温度与租车量关系	scatter	两只资产收益率关系
按年份区分点群	分组颜色	不同时段或行业的关系差异


这些绘图方法也适用于金融数据。下章进入金融时间序列，继续讨论价格与收益率。



- 数据: Hadi Fanaee-T (2013), *Bike Sharing*, UCI, CC BY 4.0.^[1]
- 数据论文: Fanaee-T and Gama, *Event labeling combining ensemble detectors and background knowledge*.^[2]
- Python 绘图背景: *Python 金融大数据分析*第 7 章。^[3]
- 扩展阅读: *Python for Data Analysis*, 第 9 章。

数据保留官方文件; 中文叙述、分析顺序、图形与练习由本课程编写。温度保留标准化尺度, 未使用有歧义的摄氏度换算。



- 
- [1] FANAEE-T H. Bike Sharing[EB/OL]. UCI Machine Learning Repository, 2013 [2026-09-24].
<https://doi.org/10.24432/C5W894>.
- [2] FANAEE-T H, GAMA J. Event labeling combining ensemble detectors and background knowledge[J/OL]. Progress in Artificial Intelligence, 2013 [2026-09-24].
<http://dx.doi.org/10.1007/s13748-013-0040-3>.
- [3] 伊夫·希尔皮斯科. Python 金融大数据分析 [M]. 2nd ed. 北京: 人民邮电出版社, 2018.

Thanks for your attention!

Q & A

