Python 金融数据分析

第 6 章　金融时间序列

主讲人:　王伟冠, 吕文俊
院　系:　经济学院金融系

上海大学

2026 年 11 月 5 日



1. 真实数据登场

2. 收益率：金融数据的”通用语言”

3. 滚动统计与波动率聚集

4. 收益率分布与厚尾

5. 回归分析：beta 是怎么算出来的

6. 小结与练习

1. 真实数据登场

2. 收益率：金融数据的”通用语言”

3. 滚动统计与波动率聚集

4. 收益率分布与厚尾

5. 回归分析：beta 是怎么算出来的

6. 小结与练习

本章学习目标

- 首次使用**真实市场数据**：2010–2018 年美股、指数、外汇、黄金
- 掌握收益率的两种算法：简单收益率与对数收益率，及其适用场景
- 会用滚动窗口计算移动平均与滚动波动率，观察波动率聚集
- 理解收益率分布的厚尾现象及其风险管理含义
- 会用 OLS 回归估计股票的 beta，理解相关与回归的区别

本章数据

教材配套数据集 `eod_data.csv`（来源：Refinitiv Eikon），12 个资产的日频收盘价。

读入真实数据

```python
import numpy as np
import pandas as pd

df = pd.read_csv("../data/eod_data.csv",     # 本章data目录
                 index_col=0,        # 第0列(日期)作索引
                 parse_dates=True)   # 解析成日期类型
df.shape           # (2216, 12): 8年半, 2216个日期
df.columns.tolist()
```

```
['AAPL.O', 'MSFT.O', 'INTC.O', 'AMZN.O', 'GS.N', 'SPY',
 '.SPX', '.VIX', 'EUR=', 'XAU=', 'GDX', 'GLD']
```

- 个股（苹果、微软...）、标普 500 指数.SPX、波动率指数.VIX、欧元汇率 EUR=、黄金 XAU= 等。
- 不同市场的交易日不完全重合，所以表里有 NaN——真实数据的常态。

数据体检：缺失值在哪里？

```python
df.isna().sum()       # 每列缺失个数
df = df.dropna(subset=["SPY", "AAPL.O"])  # 只保留美股交易日
df.shape              # (2138, 12)
```

- 以 SPY（美股 ETF）为准过滤日期：只研究美股交易日。
- 其他资产（黄金、外汇）在美股假日缺失的部分仍保留为 NaN，后续用到时再单独处理。

零基础提醒

NaN 参与任何运算结果都是 NaN；统计函数（mean/std）会自动跳过它——但要知道它存在。

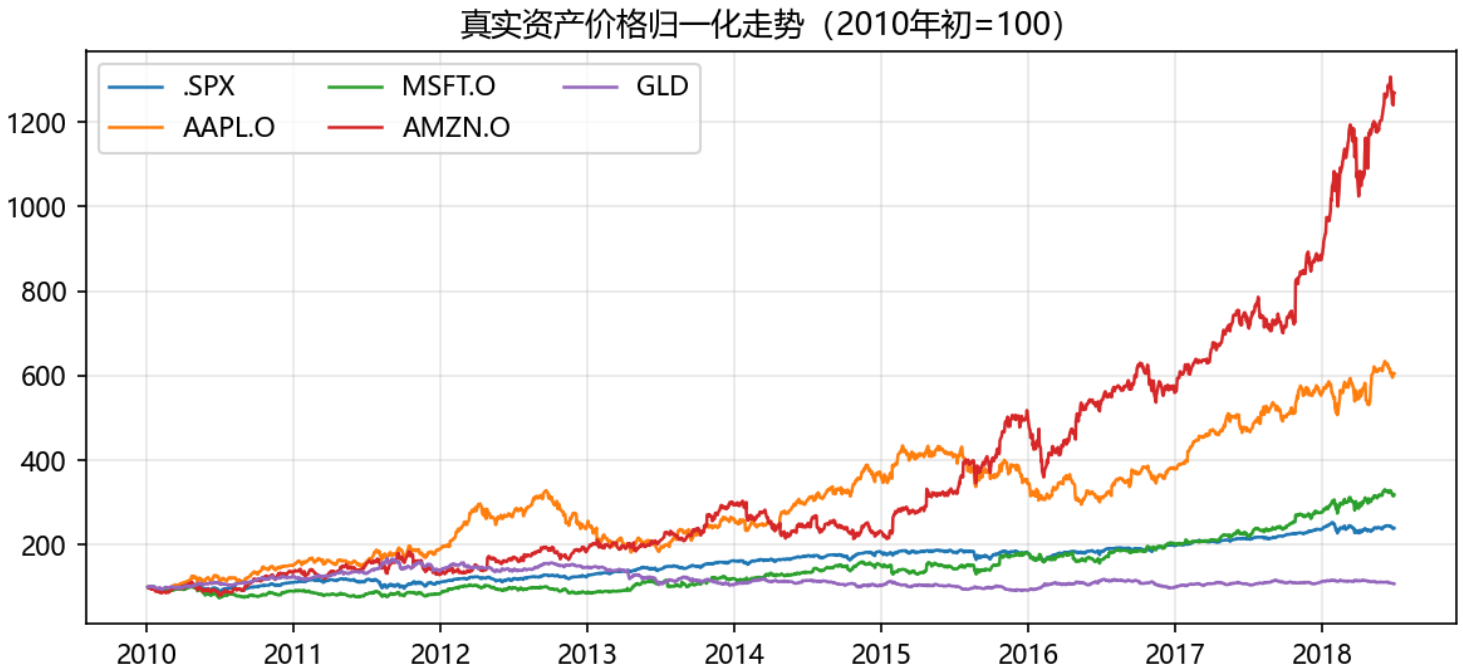


图 1: 各资产以 2010 年初为 100 归一化——苹果、微软、亚马逊八年间的巨大涨幅一目了然

归一化的代码

```
sel = [".SPX", "AAPL.O", "MSFT.O", "AMZN.O", "GLD"]
norm = df[sel] / df[sel].iloc[0] * 100   # 起点=100
norm.plot(figsize=(8, 4), grid=True)
```

- 不同资产价格量级差异大（黄金上千、汇率 1.4），直接画没法比。
- 除以各自首日价格再乘 100：把"价格"变成"涨跌幅指数"。
- 向量化除法对整个 DataFrame 生效——第 3、4 章功力的直接应用。

1. 真实数据登场

2. 收益率：金融数据的”通用语言”

3. 滚动统计与波动率聚集

4. 收益率分布与厚尾

5. 回归分析：beta 是怎么算出来的

6. 小结与练习

简单收益率 vs 对数收益率

```python
simple = df["SPY"].pct_change()          # (今日-昨日)/昨日
logret = np.log(df["SPY"] / df["SPY"].shift(1))
logret.head()
```

```
Date
2010-01-04         NaN
2010-01-05    0.002644
2010-01-06    0.000704
Freq: B, Name: SPY, dtype: float64
```

- 对数收益率 $r_t = \ln(P_t/P_{t-1})$；日常涨跌小时，两者数值几乎相同。
- 对数收益率的优点：可以直接加总——日收益相加即区间收益。

为什么要取对数?

$\ln(P_T/P_0) = \ln(P_T/P_{T-1}) + \cdots + \ln(P_1/P_0)$，简单收益率连乘才等价，统计建模中加法形式友好得多。

一张表算出所有资产的收益率

```
rets = np.log(df / df.shift(1))    # 12列一次全算
rets.describe().round(4)           # 每列的统计摘要
```

- `df / df.shift(1)`：整表除以"昨天的自己"。
- 第一行全是 NaN（没有"昨天"）——`dropna()` 或让函数自动跳过。
- 观察 `describe()`：均值接近 0、标准差差异大（VIX 日波动最大）。

年化：从日到年

年化均值 $\approx$ 日均值 $\times 252$；年化波动率 $=$ 日波动率 $\times \sqrt{252}$。
252 是一年的交易日数，金融计算的常用常数。

```python
rets.mean() * 252                 # 年化平均收益
rets.std() * np.sqrt(252)         # 年化波动率
(rets["AAPL.O"] * 252).round(3)   # 苹果：约0.21（21%）
```

- 为什么波动率乘 $\sqrt{252}$ 而不是 252？方差按时间线性累加，标准差（波动率）按平方根累加。
- 比较不同资产的风险收益，必须放在同一时间尺度上——年化是行业标准。

重采样：日频 → 月频/年频

```python
df.resample("ME").last()      # 每月最后一个交易日的价格
df.resample("YE").last()      # 每年最后一个交易日
rets.resample("ME").sum()     # 对数收益按月加总=月收益
```

- 真实分析常需要换频率：月报、年度回顾、周度策略。
- 价格取 `last`，对数收益取 `sum`——语义不同，别混用。

1. 真实数据登场

2. 收益率：金融数据的”通用语言”

3. 滚动统计与波动率聚集

4. 收益率分布与厚尾

5. 回归分析：beta 是怎么算出来的

6. 小结与练习

rolling：移动窗口

```python
spy = rets["SPY"].dropna()
ma21  = spy.rolling(21).mean()    # 21日移动平均
vol21 = spy.rolling(21).std() * np.sqrt(252)  # 滚动年化波动率
vol21.head(25)    # 前20个是NaN：窗口不足
```

- `rolling(n)`：每次取最近 n 个数据算统计量，窗口逐日滑动。
- 前 $n-1$ 个结果为 `NaN`——数据不足，正常现象。
- 技术分析中的 MA5、MA20、MA60 就是不同窗口的移动平均。

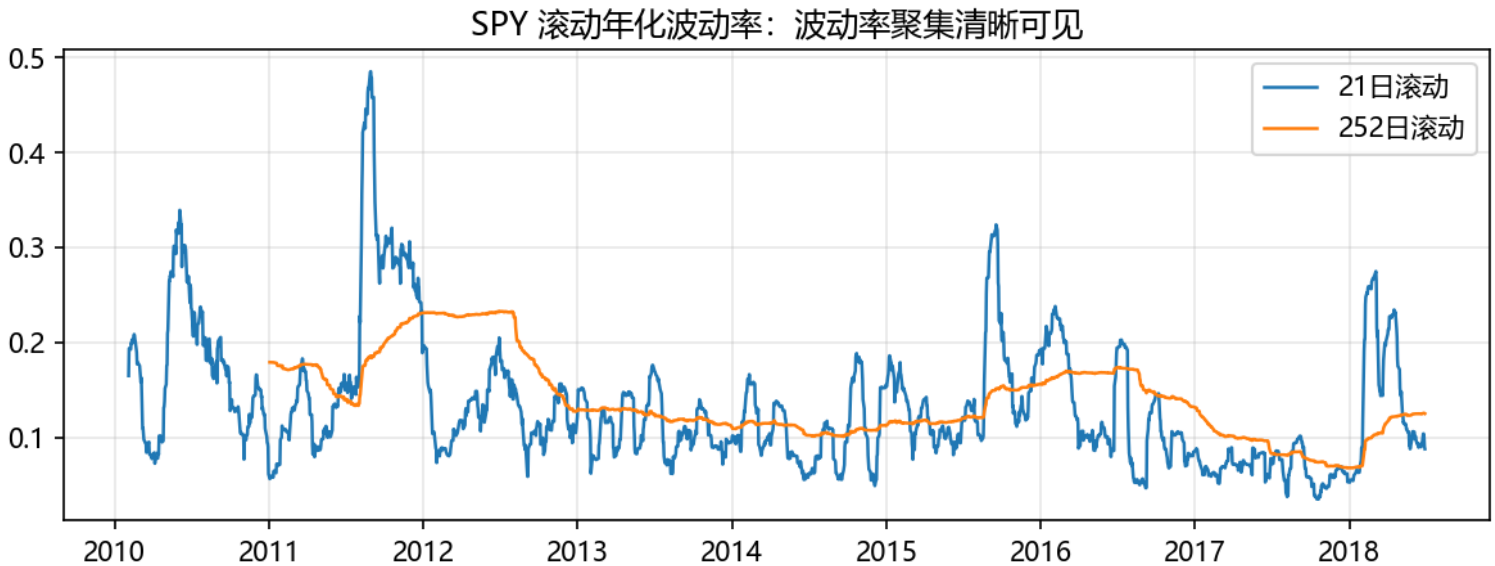


图 2: SPY 滚动年化波动率：2011 年欧债危机、2015 年人民币汇改与 2018 年初的波动尖峰

波动率聚集的要点

- 波动率不是平稳的：平时低，危机时突然飙升，然后缓慢回落。
- 这个现象叫**波动率聚集**（volatility clustering），是金融时间序列最著名的"程式化事实"之一。
- 实际意义：
  - 风险度量（VaR）必须用最近的数据，而不是八年平均；
  - 21 日窗口反应快但噪声大，252 日窗口平滑但迟钝——窗口选择是权衡。

不要犯的错

用全样本的标准差代表"日常风险"——会严重低估危机时期的损失。

1. 真实数据登场

2. 收益率：金融数据的”通用语言”

3. 滚动统计与波动率聚集

4. 收益率分布与厚尾

5. 回归分析：beta 是怎么算出来的

6. 小结与练习

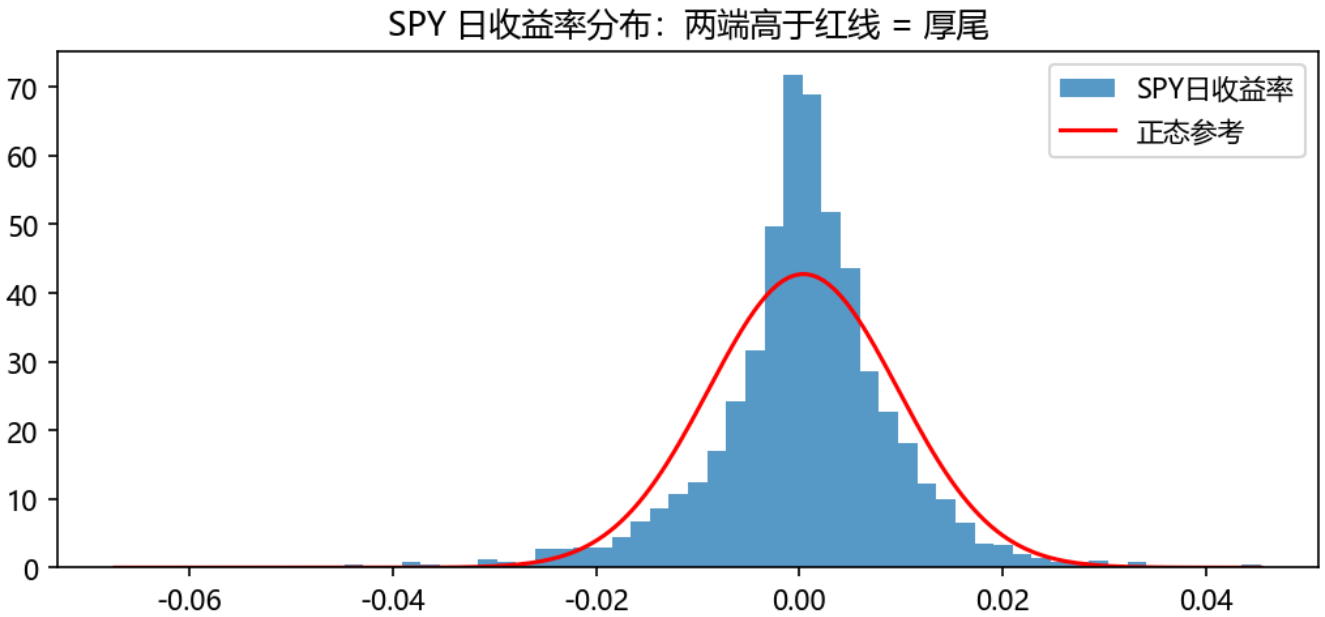


图 3: 直方图与正态分布（红线）对比：两端的柱子明显高于红线

厚尾的定量证据

```python
r = rets["SPY"].dropna()
(r.abs() > 0.03).sum()     # 日收益 >3% 的天数
```

```
27
```

- 8 年半约 2137 个交易日，按正态分布（日标准差约 1%）计算，$|r| > 3\%$ 几乎不可能发生（理论上不到 1 天），实际却有 27 天。
- 单日涨跌超 3% 在正态下是"万年一遇"，现实中平均每三个月就出现一次。

风险管理核心教训

厚尾：极端行情远比正态分布预想的频繁。模型假设正态，会系统性低估尾部风险。

1. 真实数据登场

2. 收益率：金融数据的”通用语言”

3. 滚动统计与波动率聚集

4. 收益率分布与厚尾

5. 回归分析：beta 是怎么算出来的

6. 小结与练习

- 资本资产定价模型（CAPM）：个股收益与市场收益线性相关

$$r_i = \alpha_i + \beta_i\, r_m + \varepsilon_i$$

- β：股票对市场波动的敏感度。$\beta = 1$ 与市场同步；$\beta > 1$ 放大波动；$\beta < 1$ 相对稳健。
- 估计方法：把历史日收益做**最小二乘回归**（OLS）。

```
x = rets[".SPX"].dropna()       # 市场收益
y = rets["AAPL.O"].dropna()     # 苹果收益
beta, alpha = np.polyfit(x, y, 1)   # 一元线性拟合
round(beta, 2)
```

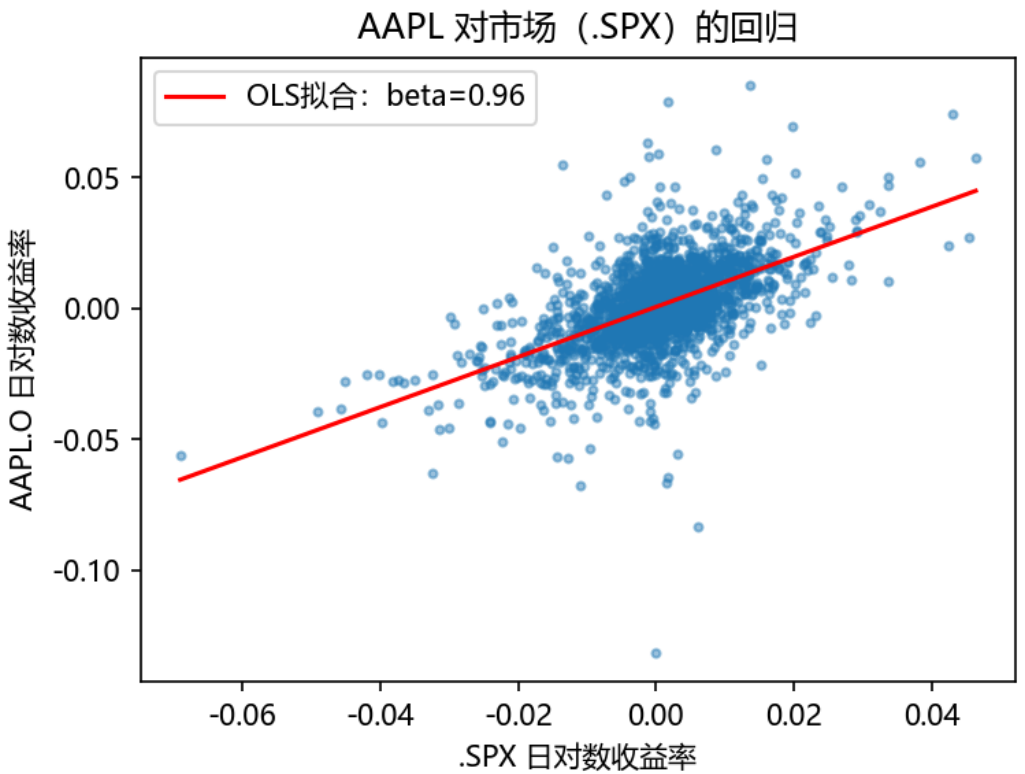


图 4: AAPL 对.SPX 日收益回归：beta ≈ 0.96，接近市场平均水平

相关系数 vs 回归系数

```
x.corr(y)     # 相关系数：约0.57
```

- **相关系数**衡量"联动紧密程度"，范围 $[-1, 1]$；
- **beta** 衡量"市场涨 1%，个股平均涨多少"，可以大于 1 或为负。
- 两者关系：$\beta = \rho \cdot \sigma_i / \sigma_m$。

换个视角：VIX 恐慌指数

`df[".VIX"].corr(日收益)` 为负（约 -0.18）：市场恐慌升高时，股价倾向下跌。VIX 常被称为"恐慌指数"。

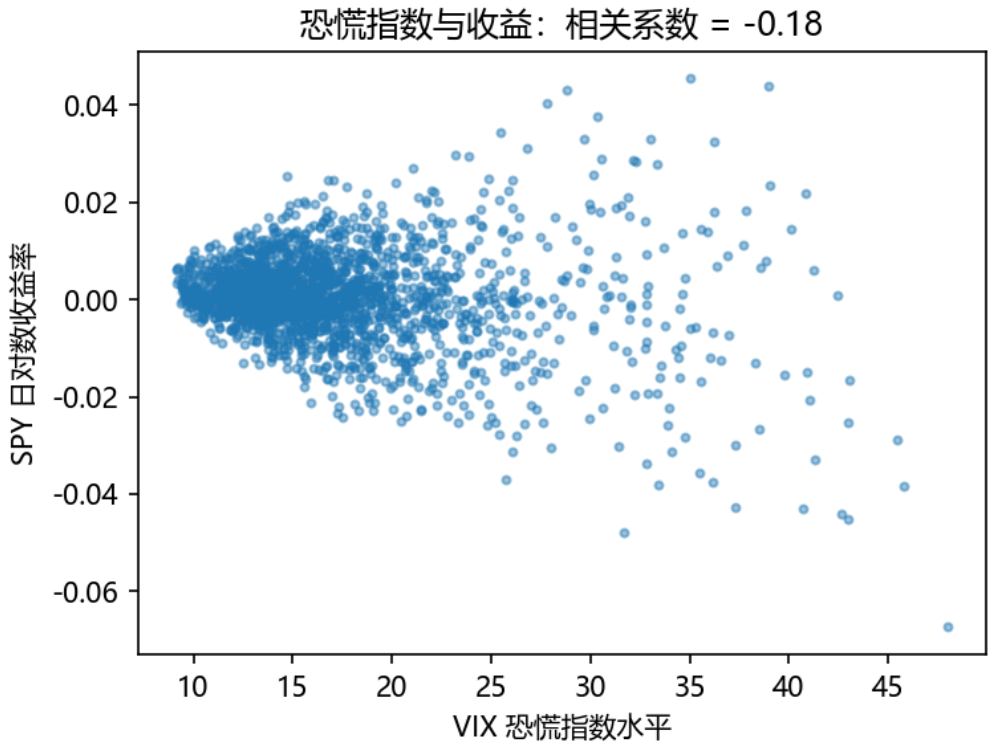


图 5: VIX 越高（横轴右侧），SPY 日收益越倾向为负

1. 真实数据登场

2. 收益率：金融数据的”通用语言”

3. 滚动统计与波动率聚集

4. 收益率分布与厚尾

5. 回归分析：beta 是怎么算出来的

6. 小结与练习

- **真实数据**：`read_csv` + 缺失值处理（`dropna`）是第一步。
- **收益率**：对数收益率可加性好，是建模首选；年化规则：均值 $\times 252$，波动率 $\times \sqrt{252}$。
- **滚动窗口**：`rolling(n).mean()/std()`——移动平均与滚动波动率；波动率聚集要求风险度量用近期数据。
- **厚尾**：极端行情比正态假设更常见，风险管理不能只靠均值方差。
- **回归**：`np.polyfit` 一行估计 beta；相关系数说联动程度，beta 说敏感度。

课后任务

1. 对 MSFT.O 重复 beta 回归，比较与苹果的 beta 大小，并结合两家公司的业务特点给出解释。
2. 把滚动波动率窗口从 21 改为 63（一个季度），观察图形平滑程度的变化。
3. 选做：统计 $|r| > 5\%$ 的天数，查一查这些日期分别对应什么历史事件，进一步体会厚尾。

下章预告

数据从哪来？下一章讲**数据输入输出**：CSV、Excel、HDF5，以及更大规模数据的存取方式。

本章内容改编自教材第 8 章[1]。

[1] 伊夫·希尔皮斯科. Python 金融大数据分析 [M]. 2nd ed. 北京 : 人民邮电出版社, 2018.



Thanks for your attention!

Q & A