
Python 金融数据分析

第 6 章 金融时间序列

主讲人： 王伟冠, 吕文俊
院 系： 经济学院金融系

上海大学

2026 年 9 月 24 日



1. 真实数据登场
2. 收益率：金融数据的“通用语言”
3. 滚动统计与波动率聚集
4. 收益率分布与厚尾
5. 回归分析：beta 是怎么算出来的
6. 小结与练习



1. 真实数据登场
2. 收益率：金融数据的“通用语言”
3. 滚动统计与波动率聚集
4. 收益率分布与厚尾
5. 回归分析：beta 是怎么算出来的
6. 小结与练习



- 首次使用**真实市场数据**：2010–2018 年美股、指数、外汇、黄金
- 掌握收益率的两种算法：简单收益率与对数收益率，及其适用场景
- 会用滚动窗口计算移动平均与滚动波动率，观察**波动率聚集**
- 理解收益率分布的**厚尾**现象及其风险管理含义
- 会用 OLS 回归估计股票的 β ，理解相关与回归的区别

本章数据

教材配套数据集 `eod_data.csv` (来源: Refinitiv Eikon), 12 个资产的日频收盘价。

```
1 import numpy as np
2 import pandas as pd
3
4 df = pd.read_csv("../data/eod_data.csv",      # 本章data目录
5                  index_col=0,                # 第0列(日期)作索引
6                  parse_dates=True)          # 解析成日期类型
7 df.shape                                     # (2216, 12): 8年半, 2216个日期
8 df.columns.tolist()
```

```
1 ['AAPL.O', 'MSFT.O', 'INTC.O', 'AMZN.O', 'GS.N', 'SPY',
2  '.SPX', '.VIX', 'EUR=', 'XAU=', 'GDX', 'GLD']
```

- 个股 (苹果、微软...)、标普 500 指数.SPX、波动率指数.VIX、欧元汇率 EUR=、黄金 XAU= 等。
- 不同市场的交易日不完全重合，所以表里有 NaN——真实数据的常态。

```
1 df.isna().sum()      # 每列缺失个数
2 df = df.dropna(subset=["SPY", "AAPL.O"]) # 只保留美股交易日
3 df.shape             # (2138, 12)
```

- 以 SPY（美股 ETF）为准过滤日期：只研究美股交易日。
- 其他资产（黄金、外汇）在美股假日缺失的部分仍保留为 NaN，后续用到时再单独处理。

零基础提醒

NaN 参与任何运算结果都是 NaN；统计函数（mean/std）会自动跳过它——但要知道它存在。



图 1: 各资产以 2010 年初为 100 归一化——苹果、微软、亚马逊八年间的巨大涨幅一目了然

```
1 sel = [".SPX", "AAPL.O", "MSFT.O", "AMZN.O", "GLD"]
2 norm = df[sel] / df[sel].iloc[0] * 100 # 起点=100
3 norm.plot(figsize=(8, 4), grid=True)
```

- 不同资产价格量级差异大（黄金上千、汇率 1.4），直接画没法比。
- 除以各自首日价格再乘 100：把“价格”变成“涨跌幅指数”。
- 向量化除法对整个 DataFrame 生效——第 3、4 章功力的直接应用。

1. 真实数据登场
- 2. 收益率：金融数据的“通用语言”**
3. 滚动统计与波动率聚集
4. 收益率分布与厚尾
5. 回归分析：beta 是怎么算出来的
6. 小结与练习



```
1 simple = df["SPY"].pct_change()          # (今日-昨日)/昨日
2 logret = np.log(df["SPY"] / df["SPY"].shift(1))
3 logret.head()
```

```
1 Date
2 2010-01-04      NaN
3 2010-01-05    0.002644
4 2010-01-06    0.000704
5 Freq: B, Name: SPY, dtype: float64
```

- 对数收益率 $r_t = \ln(P_t/P_{t-1})$; 日常涨跌小时, 两者数值几乎相同。
- 对数收益率的优点: 可以直接加总——日收益相加即区间收益。

为什么要取对数?

$\ln(P_T/P_0) = \ln(P_T/P_{T-1}) + \cdots + \ln(P_1/P_0)$, 简单收益率连乘才等价, 统计建模中加法形式友好得多。

```
1 rets = np.log(df / df.shift(1)) # 12列一次全算
2 rets.describe().round(4)       # 每列的统计摘要
```

- `df / df.shift(1)`: 整表除以“昨天的自己”。
- 第一行全是 NaN (没有“昨天”) ——`dropna()` 或让函数自动跳过。
- 观察 `describe()`: 均值接近 0、标准差差异大 (VIX 日波动最大)。

年化: 从日到年

年化均值 $\approx$ 日均值 $\times 252$; 年化波动率 = 日波动率 $\times \sqrt{252}$ 。
252 是一年的交易日数, 金融计算的常用常数。

```
1 rets.mean() * 252          # 年化平均收益
2 rets.std() * np.sqrt(252)  # 年化波动率
3 (rets["AAPL.O"] * 252).round(3) # 苹果: 约0.21 (21%)
```

- 为什么波动率乘 $\sqrt{252}$ 而不是 252? 方差按时间线性累加, 标准差 (波动率) 按平方根累加。
- 比较不同资产的风险收益, 必须放在同一时间尺度上——年化是行业标准。

```
1 df.resample("ME").last()      # 每月最后一个交易日的价格
2 df.resample("YE").last()      # 每年最后一个交易日
3 rets.resample("ME").sum()     # 对数收益按月加总=月收益
```

- 真实分析常需要换频率：月报、年度回顾、周度策略。
- 价格取 last，对数收益取 sum——语义不同，别混用。

1. 真实数据登场
2. 收益率：金融数据的“通用语言”
- 3. 滚动统计与波动率聚集**
4. 收益率分布与厚尾
5. 回归分析：beta 是怎么算出来的
6. 小结与练习



```
1 spy = rets["SPY"].dropna()
2 ma21 = spy.rolling(21).mean() # 21日移动平均
3 vol21 = spy.rolling(21).std() * np.sqrt(252) # 滚动年化波动率
4 vol21.head(25) # 前20个是NaN: 窗口不足
```

- `rolling(n)`: 每次取最近 n 个数据算统计量, 窗口逐日滑动。
- 前 $n - 1$ 个结果为 NaN——数据不足, 正常现象。
- 技术分析中的 MA5、MA20、MA60 就是不同窗口的移动平均。




图 2: SPY 滚动年化波动率：2011 年欧债危机、2015 年人民币汇改与 2018 年初的波动尖峰

- 波动率不是平稳的：平时低，危机时突然飙升，然后缓慢回落。
- 这个现象叫**波动率聚集** (volatility clustering)，是金融时间序列最著名的“程式化事实”之一。
- 实际意义：
 - 风险度量 (VaR) 必须用**最近**的数据，而不是八年平均；
 - 21 日窗口反应快但噪声大，252 日窗口平滑但迟钝——窗口选择是权衡。

不要犯的错

用全样本的标准差代表“日常风险”——会严重低估危机时期的损失。

1. 真实数据登场
2. 收益率：金融数据的“通用语言”
3. 滚动统计与波动率聚集
- 4. 收益率分布与厚尾**
5. 回归分析：beta 是怎么算出来的
6. 小结与练习






图 3: 直方图与正态分布 (红线) 对比: 两端的柱子明显高于红线

```
1 r = rets["SPY"].dropna()
2 (r.abs() > 0.03).sum()    # /日收益 />3%的天数
```

```
1 27
```

- 8 年半约 2137 个交易日，按正态分布（日标准差约 1%）计算， $|r| > 3\%$ 几乎不可能发生（理论上不到 1 天），实际却有 27 天。
- 单日涨跌超 3% 在正态下是“万年一遇”，现实中平均每三个月就出现一次。

风险管理核心教训

厚尾：极端行情远比正态分布预想的频繁。模型假设正态，会系统性低估尾部风险。

1. 真实数据登场
2. 收益率：金融数据的“通用语言”
3. 滚动统计与波动率聚集
4. 收益率分布与厚尾
5. 回归分析：beta 是怎么算出来的
6. 小结与练习



- 资本资产定价模型 (CAPM): 个股收益与市场收益线性相关

$$r_i = \alpha + \beta r_m + \varepsilon$$

- β : 股票对市场波动的敏感度。 $\beta = 1$ 与市场同步; $\beta > 1$ 放大波动; $\beta < 1$ 相对稳健。
- 估计方法: 把历史日收益做**最小二乘回归** (OLS)。

```
1 x = rets[".SPX"].dropna()      # 市场收益
2 y = rets[".AAPL.O"].dropna()   # 苹果收益
3 beta, alpha = np.polyfit(x, y, 1) # 一元线性拟合
4 round(beta, 2)
```




图 4: AAPL 对 .SPX 日收益回归: $\beta \approx 0.96$, 接近市场平均水平



```
1 x.corr(y)    # 相关系数: 约0.57
```

- **相关系数**衡量“联动紧密程度”，范围 $[-1, 1]$ ；
- **beta** 衡量“市场涨 1%，个股平均涨多少”，可以大于 1 或为负。
- 两者关系： $\beta = \rho \cdot \sigma_i / \sigma_m$ 。

换个视角：VIX 恐慌指数

`df[".VIX"].corr(日收益)` 为负（约 -0.18 ）：市场恐慌升高时，股价倾向下跌。VIX 常被称为“恐慌指数”。




图 5: VIX 越高 (横轴右侧), SPY 日收益越倾向为负



1. 真实数据登场
2. 收益率：金融数据的“通用语言”
3. 滚动统计与波动率聚集
4. 收益率分布与厚尾
5. 回归分析：beta 是怎么算出来的
- 6. 小结与练习**



- **真实数据**: `read_csv` + 缺失值处理 (`dropna`) 是第一步。
- **收益率**: 对数收益率可加性好, 是建模首选; 年化规则: 均值 $\times 252$, 波动率 $\times \sqrt{252}$ 。
- **滚动窗口**: `rolling(n).mean()/std()`——移动平均与滚动波动率; 波动率聚集要求风险度量用近期数据。
- **厚尾**: 极端行情比正态假设更常见, 风险管理不能只靠均值方差。
- **回归**: `np.polyfit` 一行估计 `beta`; 相关系数说联动程度, `beta` 说敏感度。

课后任务

- ① 对 MSFT.O 重复 beta 回归, 比较与苹果的 beta 大小, 并结合两家公司的业务特点给出解释。
- ② 把滚动波动率窗口从 21 改为 63 (一个季度), 观察图形平滑程度的变化。
- ③ 选做: 统计 $|r| > 5\%$ 的天数, 查一查这些日期分别对应什么历史事件, 进一步体会厚尾。

下章预告

数据从哪来? 下一章讲**数据输入输出**: CSV、Excel、HDF5, 以及更大规模数据的存取方式。

本章内容改编自教材第 8 章^[1]。

- [1] 伊夫·希尔皮斯科. Python 金融大数据分析 [M]. 2nd ed. 北京: 人民邮电出版社, 2018.



Thanks for your attention!

Q & A

