
Python 金融数据分析

第 11 章 股票日频收益率分析

王伟冠, 吕文俊 经济学院金融系

上海大学

2026 年 9 月 24 日



三个问题

一只股票今天涨了多少？ 一段时间持有的回报是多少？
不同股票的收益分布与波动程度有什么差别？

- ① 了解中国 A 股市场的交易所、板块与证券代码。
- ② 读懂股票日数据中的价格、回报率、成交量与市值。
- ③ 用 pandas 制作累计收益率、波动率、回撤和换手率。
- ④ 用描述性统计与图表解释样本，并检查结果是否合理。

1. A 股市场与股票日数据
2. 筛选样本与检查口径
3. 收益率与基础指标
4. 描述性统计与可视化
5. 复现与解释结果



A 股是人民币普通股票。交易所是交易组织层级，板块是其市场分层。

上海证券交易所

主板

成熟企业的重要上市市场

科创板

面向科技创新企业

深圳证券交易所

主板

含原中小板

创业板

服务创新创业企业

北京证券交易所

服务创新型中小企业

2021 年 11 月 15 日开市交易

深市主板与中小板于 2021 年 4 月 6 日合并；本章不再把中小板作为独立现行板块。

来源：上交所股票分类

来源：深交所两板合并公告

来源：北交所简介；官网核对日期 2026-09-09

Marketttype	字段说明中的类别	本章处理
1	上证 A 股, 不含科创板	沪市主板
4	深证 A 股, 不含创业板	深市主板
16	创业板	保留
32	科创板	保留
64	北证 A 股	保留
2 / 8	沪市 B 股 / 深市 B 股	本章排除

- Stkcd 保存为六位字符串: 000001 不能读成整数 1。
- 市场类别、公司行业、ST 状态是不同维度。
- 本包没有证券简称、行业和代码变更映射; 不能仅据代码判断跨期公司身份。

对应 Notebook: 第 1 节; 映射依据包内字段说明

面板数据的两个维度

同一只股票在不同日期的记录构成**时间序列**；
同一天不同股票的记录构成**横截面**。

股票代码	日期	收盘价	日回报率
000001	2021-08-16	19.950	0.003017
000001	2021-08-17	19.670	-0.014035
000001	2021-08-18	20.620	0.048297

- 行的候选主键是 Stkcd + Trddt，不能只按日期去重。
- 日频数据汇总一天的交易，不能还原盘中的价格路径。
- 收益率以小数存储：0.01 表示 1%。

对应 Notebook：第 2 节；表中为原始包首三条记录



来源	本地 CSMAR 授权数据包
CSV 文件数	7
总记录数	6,888,585
证券代码数	5830 (包含 A 股、B 股)
字段数	27
日期范围	2021-08-16 至 2026-08-13
教学年份代码与日期重复键	0

数据限已有授权范围使用；代码数是本包中出现的代码数，不能直接当作官方历史上市公司总数。

对应 Notebook：2.1-2.5：从原始 ZIP 读取并计算概况

```
import zipfile
with zipfile.ZipFile(zip_path) as archive:
    print(archive.namelist())
    for member in archive.infolist():
        target = (RAW_DIR / member.filename).resolve()
        assert target.is_relative_to(RAW_DIR.resolve())
        if not target.exists():
            archive.extract(member, RAW_DIR)
```

- Notebook 从 data/中的原始 ZIP 开始，解压到 data/raw/。
- 先查看清单：7 个 CSV，以及字段说明和版权说明。
- 重复运行时保留已有文件；Windows 与 macOS 使用相同的 Python 代码。

对应 Notebook：2.1–2.2；路径变量在第 2 节设置，调用与输出都在 Notebook 中

```
preview = pd.read_csv(  
    csv_paths[0], nrows=5, encoding="utf-8-sig",  
    dtype={"Stkcd": "string"},  
    parse_dates=["Trddt", "Capchgmt"]  
)  
display(preview)  
display(preview.dtypes)
```

- `nrows=5`：先看 5 行，确认原文件结构。
- 字符串代码保留开头的零；日期类型支持提取年份。
- 同时打开刚解压的 TXT 字段说明，确认收益率与金额单位。

对应 Notebook：2.3；CSV 是文本，读入后才成为 pandas 的 DataFrame

```
year_parts = []
for csv_path in csv_paths:
    reader = pd.read_csv(
        csv_path, dtype={"Stkcd": "string"},
        parse_dates=["Trddt", "Capchgdt"],
        chunksize=150_000, encoding="utf-8-sig")
    for chunk in reader:
        year_parts.append(
            chunk.loc[chunk["Trddt"].dt.year.eq(YEAR)].copy())
raw = pd.concat(year_parts, ignore_index=True)
```

每次读取 15 万行，仅保留教学年份；concat 将各块按行拼接。
Notebook 同时统计各文件行数和全包覆盖，再检查年度重复键与价格关系。

对应 Notebook：2.4-2.5；这里展示读取主线，完整计数与检查见 Notebook

市场类型 Markettype 用于筛选 A 股与区分板块。

填充标识 Filling=0 为正常原始交易记录；1、2 分别表示非节假日和节假日填充。

交易状态 Trdsta=1 为正常状态；2 为 ST，3 为 *ST，另有历史状态代码。

填充记录不等于新增交易观测

如果直接统计全部记录，补入的零收益可能改变均值、波动率和零收益占比。

- 主样本保留 ST 与极值，但剔除填充记录。
- 同时比较只保留正常状态的子样本，展示口径敏感性。
- 未缺失不等于没有质量问题；需要检查经济含义和字段之间的关系。

对应 Notebook：2.6、3.1

```
a_share = raw[raw["Markettype"].isin([1,4,16,32,64])]
actual = a_share[a_share["Filling"].eq(0)]
traded = actual[
    actual["Dnshrtrd"].gt(0) & actual["Clsprc"].gt(0)
]
df = traded[
    np.isfinite(traded["Dretwd"]) & traded["Dretwd"].gt(-1)
].copy()
```


2025 年筛选步骤	记录数
原始记录 (含 B 股、填充)	1,435,881
A 股记录	1,414,730
非填充且有成交、收益可用	1,313,872

最终包含 5,500 个代码、243 个样本日期。这里描述的是**有成交的股票日**。

对应 Notebook：第 3 节；原始记录保留在解压后的 CSV 中

检查	本包结果与处理
股票代码 + 日期重复	教学年份未发现重复键，不自动去重
非填充记录的价格、量	无非正收盘价、负成交股数、高低价顺序矛盾
收益率边界	未发现含红利收益率小于等于 -100%
缺失值	盘后成交、涨跌停字段等有缺失；不能一律填 0
特别大的涨跌幅	保留并查事件；不能统一截到正负 10%

对应 Notebook：2.5、2.6、6 节极值核验



- 2025-12-31 当天有 5,458 个满足条件的证券代码。
- 分母是当日有成交、收益可用的样本；不等于交易所公布的上市公司数。

对应 Notebook: 3.2: groupby + nunique

指标	计算或字段	关注点
未复权价格变化	$P_t / P_{t-1} - 1$	可能受分红、送转等影响
交易所涨跌幅	ChangeRatio	使用可能已除权的交易所昨收价格
不含现金红利回报	Dretnd	不考虑现金红利
含红利回报	Dretwd	考虑现金红利再投资, 本章主口径

价格跌了，持有回报就一定为负吗？

除息可能让价格下降，而持有者收到现金红利。需要先说明回报口径，不能只看价格曲线。

对应 Notebook：第 4 节；以原包字段定义为准

```
df = df.sort_values(["Stkcd", "Trddt"])
stock = df[df["Stkcd"].eq("000001")].copy()
stock = stock.set_index("Trddt")
stock["price_return"] = stock["Clsprc"].pct_change(
    fill_method=None
)
stock["return"] = stock["Dretwd"]
```

- 不要对混在一起的多只股票直接 `pct_change()`。
- 多股票计算需要先排序，再按股票分组。
- 样本首行没有样本内的前价，价格变化率保留缺失。
- 缺失或停牌会改变相邻观测间隔；一行数据不必然对应一个连续交易日。

对应 Notebook：第 4 节

代码 000001: 2025 年 6 月 12 日

未复权价格变动约为 -1.435%;
数据库含红利回报约为 +1.620%;
交易所涨跌幅约为 +1.654%。

- 数据表显示口径差异; 仅凭该差异不推断公司事件的全部细节。
- 单股样本中, $\text{Clsprc} / \text{PreClosePrice} - 1$ 与 ChangeRatio 的最大误差约为 5×10^{-7} 。
- Adjprc wd 的相邻回报与 Dret wd 最大误差约为 5.1×10^{-10} 。

验证方法

先比较字段定义, 再用另一种计算方式交叉核对, 允许数据存储精度造成的小误差。

对应 Notebook: 第 4 节: 收益率对照表及断言

$$W_t = \prod_{s=1}^t (1 + r_s), \quad R_{1:t} = W_t - 1$$

两天的例子

第一天涨 10%，第二天跌 10%： $1.10 \times 0.90 - 1 = -1\%$ 。
简单相加得到 0%，遗漏了复利效应。

```
stock["wealth"] = (1 + stock["return"]).cumprod()
cumulative_return = stock["wealth"].iloc[-1] - 1
```

- 初始净值 1 对应**第一笔收益发生之前**。
- 示例 000001：2025 年累计收益为 2.63%，直接相加约为 3.83%。
- 上市首日回报可能以发行价为基准，不等于首日开盘买入收益。

对应 Notebook：4.1



对应 Notebook: 4.1; 证券代码 000001, 第一笔收益发生前净值 =1

$$g_t = \ln(1 + r_t), \quad \sum_{t=1}^T g_t = \ln \left[\prod_{t=1}^T (1 + r_t) \right]$$

```
stock["log_return"] = np.log1p(stock["return"])
log_based = np.exp1(stock["log_return"].sum())
np.isclose(log_based, cumulative_return)
```

- $\log1p(x)$ 计算 $\ln(1 + x)$; $\expm1(x)$ 计算 $e^x - 1$ 。
- 收益率较小时，简单收益和对数收益接近，但并不相同。
- 当 $r \leq -1$ 时不能直接取对数，因此先检查输入。
- 对数收益可跨期相加；不能据此说不同资产的组合收益也直接等于对数收益的加权平均。

对应 Notebook：4.1：两条计算路径结果核对

$$s = \sqrt{\frac{1}{n-1} \sum_{t=1}^n (r_t - \bar{r})^2}, \quad \sigma_{ann} \approx s\sqrt{252}$$

```
daily_vol = stock["return"].std(ddof=1)
annual_vol = daily_vol * np.sqrt(252)
vol20 = stock["return"].rolling(20).std() * np.sqrt(252)
```

- pandas 样本标准差默认采用分母 $n - 1$ 。
- 252 是年化约定，本章 2025 年样本实际有 243 个日期。
- 平方根年化是近似：需要可比日频观测等假设，不是未来波动预测。
- 20 观测滚动窗口不是 20 个自然日；开始的 19 条结果为空。


对应 Notebook: 4.2

$$DD_t = \frac{W_t}{\max(1, W_1, \dots, W_t)} - 1, \quad MDD = \min_t DD_t$$

```
peak = stock["wealth"].cummax().clip(lower=1)
stock["drawdown"] = stock["wealth"] / peak - 1
max_drawdown = stock["drawdown"].min()
```

- 本章用负值报告回撤；越负代表距离峰值越远。
- 将初始投入 1 纳入峰值，避免忽略样本第一天就亏损的情况。
- 示例 000001 累计收益为 2.63%，但期间最大回撤为 -13.96%。
- 年末回报不能反映持有过程中的全部风险。

对应 Notebook：4.2



对应 Notebook: 4.2; 000001 全年近似年化波动率为 16.01%

指标	经济含义与单位
成交量	Dnshrtrd: 一天成交多少股
成交额	Dnvaltrd: 一天成交多少人民币元
流通市值	Dsmvosd: 流通股数乘收盘价, 单位千元
估算换手率	成交股数 / 由流通市值反推的流通股数

$$S_t^{float} \approx \frac{Dsmvosd_t \times 1000}{P_t}, \quad Turnover_t = \frac{Volume_t}{S_t^{float}}$$

单位不统一，结果会差 1000 倍

市值先从千元转为元。这里使用本包流通市值口径估算，不能称为官方自由流通换手率。

对应 Notebook: 第 5 节

```
df["amount_100m"] = df["Dnvaltrd"] / 1e8
df["float_mv_100m"] = df["Dsmvosd"] * 1000 / 1e8
shares = df["Dsmvosd"] * 1000 / df["Clsprc"]
df["turnover"] = df["Dnshrtrd"] / shares.where(shares > 0)
df["intraday_range"] = (
    (df["Hiprc"] - df["Loprc"]) / df["PreClosePrice"]
)
```

- 成交额、市值统一到亿元，便于表格和图形展示。
- 日内高低价范围是日频摘要，不能还原盘中路径。
- 比率分母为 0 或缺失时，先处理口径；不要把不可计算的比率填成 0。
- Notebook 对昨收价格也只在大于 0 时计算范围指标。

对应 Notebook：第 5 节

观察单位	回答的问题
单只股票的日期	这只股票在一段时间内如何表现？
同一天的各股票	当天样本股票的横截面分布如何？
全部股票日混合	本样本所有可用股票日的总体分布如何？
每只股票的年度汇总	不同股票的区间回报和风险如何比较？

本章的全样本均值

每条股票日等权；观测较多的股票贡献更多行。
它不是官方指数收益率，也不是一个已经定义好的投资组合年收益率。

对应 Notebook：第 6、7 节



2025 年股票日统计	数值	含义
均值	0.168%	中心，会受极值影响
中位数	0.000%	一半观测在其上下
日标准差	4.214%	混合分布的离散程度
1% 分位数	-7.974%	左尾位置
99% 分位数	10.009%	右尾位置
最小值	-89.33%	样本最小单日回报
最大值	1211.11%	样本最大单日回报

为什么均值和中位数差别值得关注？

本样本含极大的正收益记录。平均值、标准差与高阶矩可能被少数事件显著影响，应配合分位数和业务核验。

对应 Notebook：第 6 节；所有数值以含红利收益率计算

含红利日收益率分布 | 2025年有成交A股样本



- 左图保留全部极值并使用对数计数轴；右图仅放大正负 10% 区间。
- 右图没有改变统计样本，区间外数量已标注。
- 本样本偏度为 60.48，超额峰度为 10536.94；高阶矩受极端事件影响很大。

对应 Notebook: 6.1; pandas 的 `kurt()` 是超额峰度，正态分布为 0

正向极值：920091，2025-11-21

本包含红利日回报约 +1211.11%。北交所披露确认该日为上市首日，发行价 9 元。

该收益的起点是发行价，不能理解为首日开盘买入就能获得。


负向极值：000622，2025-06-25

本包日回报约 -89.33%。公司披露确认该日进入退市整理期，首日不设价格涨跌幅限制。

- 核对了这两条记录的事件背景和表内价格公式；不是全部极值已核验。
- 不机械截断到正负 10%；LimitStatus 缺失也不能当“未涨跌停”。


来源：北交所：大鵬工业上市报道

来源：公司退市公告，深交所披露




- 此图是板块内**全部股票日混合**标准差，不是“典型股票”的年化波动率。
- 包含新股与极值；板块差异也可能来自行业、规模和上市时间。
- 观察到差异不等于板块本身造成收益或风险差异。

对应 Notebook: 6.2: `groupby().agg()`



- 每点是一个代码，至少 200 条观测；仍可能覆盖不同起止日期。
- 横轴为近似年化波动率，纵轴为代码的可用观测区间累计回报。
- 未做跨代码衔接、成本处理或策略回测，不能直接据此选股。

对应 Notebook：第 7 节：逐代码汇总



- 三个示例代码使用共同有效日期；不把缺失收益补成 0。
- 相关性描述历史共同变化，不代表因果或未来稳定关系。

对应 Notebook: 第 7 节: `pivot` → `dropna` → `corr`

- ① **原始 ZIP**：Notebook 列出包内文件，并解压到本地目录。
- ② **读取 CSV**：先试读，再逐块读取 7 个文件、选择年份、合并和检查。
- ③ **开展分析**：接着展示 A 股样本筛选、指标计算、图表和核验。
- ④ **汇总结果**：保存筛选表、板块表、统计表、相关系数及 7 张图。
- ⑤ **课件**：引用相同图表与自动生成的统计宏。

本章文件位置

data/raw/ Notebook 解压得到的原始文件
notebooks/11_ 股票日频收益率分析.ipynb 从 ZIP 开始的完整流程
outputs/ 汇总结果
latex/chapter11.tex 课件源码

更换分析参数后，需要重新执行 Notebook，并检查课件中的日期、案例与口径说明。

- 看数据先确认观察单位、时间范围、证券范围和字段单位。
- 用合适的收益口径；累计收益相乘，对数收益跨期相加。
- 波动率、回撤与换手率描述不同维度，不应互相替代。
- 统计必须说明分母；用中位数、分位数和全分布辅助均值。
- 极值先查事件，缺失先查定义；保留数据处理的可追溯路径。

继续思考

如果更换年份、只保留正常状态、改变最低观测数，结论是否改变？
若要分析行业差异或投资组合，还需要补充哪些数据和假设？

能生成统计表只是开始；能说明这些数代表什么，才是分析。

- CSMAR 本地授权包: TRDNEW_Dalylr, 7 个 CSV; 字段口径以包内说明为准。
- 上海证券交易所: 股票分类。
- 深圳证券交易所: 2021 年 4 月 6 日两板合并。
- 北京证券交易所: 本所简介。
- 北交所: 920091 于 2025 年 11 月 21 日上市, 发行价 9 元。
- 000622 公司退市公告: 2025 年 6 月 25 日进入退市整理期。

官网核对日期: 2026-09-09。

市场结构背景、原包字段定义、计算出的样本统计分别标识, 不将样本统计冒充官方市场全貌。

